

CODAGE DES NOMBRES REELS EN MACHINE


On s'intéresse ici aux nombres possédant une « *partie entière* » et une « *partie fractionnaire* », comme par exemple $(+63,3125)_{10}$ et $(-63,3125)_{10}$

I - Représentation en « virgule flottante »

Cette représentation est adoptée à partir de 1950. Les opérations arithmétiques en « *virgule flottante* » étaient initialement réalisées par programmes (Modules mathématiques d'émulation).

1°) Le format IEEE 754 simple précision :

Ce format utilise un mot de 32 bits découpé comme suit:



Avec :

- S bit de signe $\begin{cases} S = 0 & \text{le nombre est positif} \\ S = 1 & \text{le nombre est négatif} \end{cases}$
- E exposant codé sur 8 bits en « *code majoré 127* » ou « *code excédant 127* ». On dit que « *l'excès* » est de 127.
- M la mantisse normalisée (ou pas...)

a) Le « codage avec excès » de l'exposant dans la norme IEEE 754:

On ajoute à l'intervalle des valeurs des exposants effectifs E , un « *excès* » ou « *un biais* » égale à 127. A partir de E on obtient un nouvel exposant appelé « *exposant avec excès* » ou « *exposant biaisé* » que l'on notera E_b . On a alors :

$$E_b = E + 127$$

Ainsi, plutôt que d'enregistrer la valeur binaire de E dans le champ réservé à l'exposant, on stocke la valeur binaire de E_b qui est une valeur *non signée*.

Cette translation opérée sur l'intervalle des exposants effectifs est très utile car elle évite de représenter le signe de l'exposant et de traiter par conséquent les exposants négatifs. Cela permet de simplifier les calculs arithmétiques sur les nombres réels.

Inversement, à partir de la valeur binaire de l'exposant codé en machine, exposant biaisé, on peut retrouver la valeur de l'exposant effectif E par : $E = E_b - 127$


b) Codage de la mantisse normalisée

Soit M , la valeur absolue de la mantisse. La normalisation de la mantisse telle que $2^{-1} \leq |M| < 1$, fait que le bit juste après la virgule (bit le plus significatif) vaut toujours 1.

Exemple: $(0,0000000000001)_2 = 0,1 \cdot 2^{-12} = 1 \cdot 2^{-13}$

La norme IEEE choisit de ne pas représenter ce bit de façon à gagner un bit supplémentaire de précision en faisant entrer dans le champ de représentation de la mantisse le 24^{ème} bit après la virgule. Ce bit non présent dans la représentation binaire de la mantisse est appelé « bit caché » :

Exemple :



On stocke ainsi une fraction binaire de 24 bits sur un champ de 23 bits réservé à la mantisse. De ce fait M étant la fraction binaire représenté en machine, la valeur de la mantisse est considéré comme étant égale à : $(1, M)_2$

Bit caché

Ceci est vrai lorsque la mantisse peut être normalisée càd lorsque les nombre ne sont pas « très petits ».

c) Interprétation d'un mot de 32 bits :

Avec tout ce qui vient d'être exposé sur le *codage du signe, de l'exposant* et de *la mantisse*, l'interprétation d'un mot de 32 bits codant un nombre réel en virgule flottante dans la norme IEEE simple précision est donnée par la relation :

$$\left\{ \begin{array}{l} N = (-1)^s \times (1, M)_2 \times 2^{(E_b - 127)} \quad \text{si } \begin{array}{l} 0 < E_b < 255 \\ (00000000)_2 < E_b < (11111111)_2 \end{array} \\ N = (-1)^s \times (0, M)_2 \times 2^{(-126)} \quad \text{si } E_b = 0 \text{ et } M \neq 0 \end{array} \right.$$

S : Bit de signe

ATTENTION : c'est $(1, M)_2$ et $(0, M)_2$ exprimés en BASE 2

Remarque :

La norme IEEE utilise des « **nombres dénormalisés** » pour représenter les résultats de calcul dont la valeur est inférieure à $1,0 \cdot 2^{E_{\min}}$ c-à-d pour lesquels **Eb=0**. Dans ce cas **M** est représentée telle quelle sans qu'elle puisse être normalisée.

$$E_{\min} = -126 \quad \text{et} \quad E_{\max} = +127$$

Exemples :

Quel est le nombre réel simple précision codé sur le mot de 32 bits suivant?

1	10000010	101110000000000000000000
---	----------	--------------------------

- **S=1**, le nombre réel représenté est **négatif**
- **E_b** = (10000010)₂ = (130)₁₀
- **M** = (0, 10111)₂ = (0,71875)₁₀

$$\begin{aligned} \text{D'où } N &= (-1)^1 \times (1 + 0,71875)_{10} \times 2^{(130-127)} \\ N &= (-1,71875)_{10} \times 2^3 \\ N &= \mathbf{(-13,75)_{10}} \end{aligned}$$

Quel est le nombre réel simple précision codé sur le mot de 32 bits suivant ?

0	00000000	000010100000000000000000
---	----------	--------------------------

- **S=0**, le nombre réel représenté est positif
- **E_b** = (00000000)₂ = (0)₁₀
- **M** = (0, 00001010)₂ = (0,0390625)₁₀

$$\begin{aligned} \text{D'où } N &= (-1)^0 \times (0,0390625)_{10} \times 2^{(-126)} \\ N &= \mathbf{(+4,59)_{10} \cdot 10^{-40}} \end{aligned}$$

d) Exemples de codage de nombres réels dans la norme IEEE 754 simple précision :

- Donner la représentation **(+2,5)₁₀**

- Conversion du nombre en base 2 :

$$(2)_{10} = (10)_2$$

$$0,5 \times 2 = 1 \quad \text{PE}=1 \quad 1-1=0$$

$$0,5 = (0,1)_2$$


$$(+2,5)_{10} = (10, 1)_2$$

- Normalisation de la mantisse :

$$(10, 1)_2 = (1, \mathbf{01})_2 \cdot 2^1$$

$$E_b = E + 127 = 1 + 127 = 128 = (100000000)_2$$

- Représentation binaire :



en hexa

- Donner la représentation $(-63,87)_{10}$

- Conversion du nombre en base 2 :

$$(+63,87)_{10} = (111111, 110111101011100001)_2$$

$$0,87 = (0,110111101011100001)_2$$

- Normalisation de la mantisse :

$$(111111, 110111101011100001)_2 = (1, 11111110111101011100001)_2 \cdot 2^5$$

- Calcul de l'exposant biaisé :

$$E_b = E + 127 = 5 + 127 = 132 = (10000100)_2$$

- * Représentation binaire :



en hexa


ATTENTION: Il n'y a pas ici de notion de complément à 2!!!! Le signe est simplement donné par le bit de poids fort !!
que les signes

- e) Intervalle des nombres réels représentables dans la norme IEEE 754 simple précision :

Remarques :

- Les exposants 00000000 et 11111111 sont interdits,
- l'exposant biaisé 00000000 signifie que le nombre est dénormalisé,
- l'exposant 11111111 indique que l'on n'a pas affaire à un nombre (on note cette configuration NaN (Not a Number) et on l'utilise pour signaler des erreurs de calculs, comme par exemple une division par 0).
- Le plus petit exposant est donc -126, et le plus grand +127.

- Le plus grand nombre positif




$$N_{\max} \approx + (1,1111....11)_2 . 2^{254-127} \approx + 3,4 . 10^{+38}$$

- Le plus petit nombre positif



$$N = (0,000 \dots 01) \times 2^{(-126)} \approx 1,4 \times 10^{-45}$$



Précision approximative : $2^{-23} \approx 10^{-7}$

Valeurs Spéciales :

La caractéristique principale de la norme IEEE, est que le calcul continue en présence de situations exceptionnelles :

- Lorsque le **nombre est trop petit** pour être représenté, il est **assimilé à zéro** en machine représenté par **un mot de 32 bits à Zéro**

S=0 E_b=00000000 M=0000000.....0000.

On dit qu'il y a « *souppassement de capacité* » ou « *Underflow* ».

$$(E = E_{\min} - 1 = -127)$$

- Lorsque le **nombre est trop grand** pour être représenté, il y a « *dépassement de capacité* » ou « *Overflow* ». **Le nombre est assimilé à $-\infty$ ou $+\infty$.**

$+\infty$ est représenté par **S=0, E_b = 11111111** (E=E_{max} +1= 128), **M = 00000.....0000000**

$-\infty$ est représenté par **S=1, E_b = 11111111** (E=E_{max} +1= 128), **M = 00000.....0000000**

- L'arithmétique IEEE définit des valeurs **NaN** (Not a Number) qui est un code d'erreur indiquant que la valeur codée n'est pas correcte : **la série de bits ne forme pas un nombre normal**. Cette configuration de bits est donnée par :

S=0, E_b = 11111111 (E= E_{max} +1= 128) et **M $\neq$ 0.**

f) **Le format IEEE 754 double précision :**

Ce format utilise deux mots de 32 bit, soit 64 bits, découpés comme :



Le choix de stockage en mémoire d'un nombre réel sous ce format se fait à l'aide des instructions appropriées du langage : **déclaration de variables « double float »** en C,

On étend ainsi le format de représentation pour une **meilleure précision** (mantisse à 52 bits significatifs) et **accroître l'intervalle de représentation** des nombres réels.

E, exposant codé sur 11 bits en « **code excédant 1023** »

➤ **L'interprétation d'un mot de 64 bits s'effectue par :**

$$N = (-1)^s \times (1, M) \times 2^{E_b - 1023} \quad \text{Si } E_b \neq 0 \quad \text{et } E_b \neq 2047$$

$$N = (-1)^s \times (0, M) \times 2^{-1023} \quad \text{Si } E_b = 0$$

➤ $E_{\min} = -1022 \quad \text{et} \quad E_{\max} = +1023$

➤ **Plus petit nombre positif :** $N_{\min} \approx + 2^{-52} \times 2^{-1023} = 10^{-324}$

➤ **Plus grand nombre positif :** $N_{\max} \approx + 2 \times 2^{2046-1023} \approx 10^{+308}$

➤ **Précision approximative :** $2^{-52} \approx 10^{-15}$