


2 - DÉMARCHE DE CONCEPTION



- Le contrôle de qualité
- La Modélisation
 - Rappel MCD
 - Les extensions du MCD (Héritages – contraintes entre associations)
 - MLD
- La normalisation
 - Dépendances fonctionnelles
 - Les formes normales
- Dénormalisation
 - Datawarehouse
 - Techniques de dénormalisation
 - Modèle étoile – flocon de neige

CLAUDE BOUBY - JÉRÔME GRASSET

BUT2 INFO - R4.03 - BDD AV


janv.-26

31

31

CONTRÔLE QUALITE

- **Rôle de la BDD :**



- **Le manque de qualité** d'une base de données peut entraîner :
 - **Des coûts directs**
 - perte de temps, perte d'informations, coûts de correction ou remplacement
 - **Des coûts indirects**
 - des dommages à la réputation

CLAUDE BOUBY - JÉRÔME GRASSET

BUT2 INFO - R4.03 - BDD AV

janv.-26

32

32

■ Création de la BDD

- Conception en adéquation avec les besoins réels
- Normalisation de la BDD

■ Saisie des données


- IHM (Interface utilisateur) ergonomique
- Vérification de la cohérence des données (PS – triggers)
- Aide aux utilisateurs


■ Maintenance de la BDD

- BDD évolutive (SI en constante évolution)



LA MODELISATION

■ Démarche de conception d'une BDD



MCD

validation

**MLD****MPD**

CLAUDE BOUBY - JÉRÔME GRASSET

BUT2 INFO - R4.03 - BDD AV




janv.-26

35

35

Rappel MCD**Les concepts**

- Entité – Propriétés – Identifiant
- Association
- Cardinalités

**Illustration**

CLAUDE BOUBY - JÉRÔME GRASSET

BUT2 INFO - R4.03 - BDD AV


janv.-26

36

36

■ Les extensions du MCD


■ Héritage



37

■ Héritage : les solutions d'implémentation

- chaque objet devient table avec migration de l'identifiant ou du contenu
- suppression du super-type ou des sous-types avec migration des champs vers la ou les tables existantes



CLAUDE BOUBY - JÉRÔME GRASSET






BUT2 INFO - R4.03 - BDD AV

janv.-26

38

38

■ Les 4 solutions :



- 1) Duplication de l'identifiant du sur-type dans les sous types
- 2) Duplication complète du sur-type dans les sous-types
- 3) Suppression du sur-type avec migration de son contenu dans les sous-types
- 4) Suppression des sous-types avec migration de leur contenu dans le sur-type

CLAUDE BOUBY - JÉRÔME GRASSET

BUT2 INFO - R4.03 - BDD AV




janv.-26

39

39

■ Contraintes entre associations

- Totalité
- Partition
- Égalité (S) simultanée



CLAUDE BOUBY - JÉRÔME GRASSET


BUT2 INFO - R4.03 - BDD AV

janv.-26

40

40

- Exclusion
- Insertion
- CIF



CLAUDE BOUBY - JÉRÔME GRASSET


BUT2 INFO - R4.03 - BDD AV

janv.-26

41

41

■ Exemple :



CLAUDE BOUBY

janv.-26

42


42

■ Rappel MLD

■ Concepts :

- Tables – liens - Clés primaires – Clés étrangères

■ Représentation : schéma ou textuel



RACE (Code_Race, Nom_Race, Poids, Caractere)

MAITRE (Num_Maitre, Nom_Maitre, Prenom_Maitre, Ville_Maitre, Tel_Maitre)

CHIEN (Num_Tatouage, No_Chien, Couleur_Chien, Date_Naiss_Chien, #Code_Race, #Num_Maitre)

NORMALISATION

■ Objectif :

- Une démarche de **conception** d'une **BDD Relationnelle** à partir de dépendances fonctionnelles
- Une démarche de **validation** de la structure d'un BDD existante.

■ Le principe

- La normalisation de la base de données est une démarche d'organisation des attributs de la base de données pour réduire ou éliminer la **redondance des données**.
- Divise les grandes tables en tables plus petites et liées pour minimiser la redondance des données et **garantir la cohérence** des données.
- Réduit le besoin de plusieurs mises à jour pour maintenir la cohérence.

■ Conséquences

- Donne un schéma plus complexe avec plus de tables et de relations.
- Peut avoir un impact négatif sur les performances des requêtes en raison du nombre accru de jointures requises.

■ Démarche

- Etapes successives qui progressivement vont aboutir à une BDD normalisée (organisée de manière à éviter les redondances et limiter les anomalies)
- Chaque étape exige la vérification d'une règle appelée Forme Normale (FN ou NF)
 - 7 formes normales
 - En pratique la plupart des BDD se limitent à la conformité des 3èmes FN et la BCNF (BoyceCodd)
- Le principe des FN repose sur l'identification des dépendances fonctionnelles

■ Les dépendances fonctionnelles (DF)

- Concept clé en théorie des bases de données relationnelles
- Une DF traduit la relation entre 2 ensembles d'attributs d'une table.
 - Une valeur d'un ensemble d'attributs détermine de manière unique une autre valeur d'un autre ensemble d'attributs.
 - Exemple : soit la relation $R(\text{cours, heure, jour, salle})$
On a une DF $(\text{salle, jour, heure}) \rightarrow \text{cours}$,

■ Quelques définitions

■ DF Élémentaire

- Soit C un ensemble d'attributs d'une relation R et B un attribut de R
 - $C \rightarrow B$ est une DF élémentaire si B ne dépend pas d'un sous-ensemble de C
- Une DF non élémentaire est dite **Partielle**

■ DF Transitive


- La DF $A \rightarrow C$ est transitive s'il existe B tel que $A \rightarrow B$ et $B \rightarrow C$.
- 'On peut trouver un intermédiaire pour aller de A à C '

■ DF Directe

- La DF $A \rightarrow B$ est directe s'il n'existe pas de C tel quel :
 $A \rightarrow C$ et $C \rightarrow B$ (on ne peut pas 'casser' la DF par transitivité).

■ Les formes normales

- Des lignes directrices qui permettent de garantir que la conception d'une base de données est efficace, organisée et exempte d'anomalies de données.
- Les étapes : pour passer à l'étape suivante la précédente doit être validée. (Pour être en FN x, il faut être en FN x-1)



CLAUDE BOUBY - JÉRÔME GRASSET

BUT2 INFO - R4.03 - BDD AV

janv.-26

47

47

■ Première Forme Normale 1FN

- Une relation est en 1FN si :
 - Tous ses attributs sont **atomiques**.
atomique : une seule valeur donc pas une liste de valeurs
et n'est pas une structure.
 - Elle possède au moins **une clé**

- Exemple : Soit la table EMPLOYE

EMPLOYE (Nom , adresse , Enfants)

Dupont Paul

23 rue des Lilas 87000 Limoges

Élodie, Marie, Alexandre

1FN ?

- Attributs atomiques ?

Adresse = structure (rue , cp , ville)

Enfants = liste (plusieurs valeurs)

- Clé primaire ? Nom (Nom prénom unique ?)

Solution :

Diviser tous les attributs multivalués en colonnes séparées.

Question, rechercher une clé :

clé simple – clé composée – clé candidate – nouvelle Clé séquentielle ?

CLAUDE BOUBY - JÉRÔME GRASSET

BUT2 INFO - R4.03 - BDD AV

janv.-26

48

48

■ Deuxième Forme Normale 2FN

Une entité est en 2FN si et seulement si :

- elle est en 1FN
 - Tout attribut n'appartenant pas à la clé est en DF élémentaire avec la clé (c'est à dire en DF avec toute la clé et non avec une partie seulement).
- exemple

R(NoFou, NoProd, QteProd, NomFou)

F1	P1	10	Pierre
F1	P2	20	Pierre
F2	P3	30	Jean
F3	P1	10	Jacques

1FN ok

- clé primaire NoFou, NoProd
- attributs atomiques

2FN ?

NoFou → NomFou Donc pas en 2FN

Solution :

créer une nouvelle table Fournisseur
Fournisseur (NoFou, NomFou)

■ Troisième Forme Normale : 3FN

- définition :

Une entité est en 3FN si et seulement si :

- Elle est en 2FN
- Tout attribut n'appartenant pas à la clé doit dépendre de la clé par DF élémentaire directe (donc pas de DF par transitivité sur la clé)
(tout attribut n'appartenant pas à la clé ne doit pas être en DF avec un attribut qui n'appartient pas à la clé)

- exemple

La relation R est déjà en 2FN

R(NoPiece, CodTva, TauxTva)

1FN ok > Clé primaire NoPiece
attributs atomiques

2FN ok

3FN ?

CodeTva → TauxTva

Solution créer une table TVA

TVA (CodTva, TauxTva)

■ Forme Normale de Boyce Codd - BCFN

■ définition :

- Si une entité a une clé concaténée, un des éléments composant cette clé ne doit pas dépendre d'une autre propriété.

■ exemple : Soit la relation VIN VIN(Cru, Pays, Région)

CRU	PAYS	REGION
Chenas	France	Beaujolais
Juliéna	France	Beaujolais
Morgon	France	Beaujolais
Brouilly	France	Beaujolais
Chablis	US	Californie


1FN ok
2FN ok
3FN ok

Region → Pays

Solution :

Créer une nouvelle table REG
REG (Region, Pays)

■ Synthèse



■ **Exemple** : source : <https://www.ionos.fr/digitalguide/hebergement/aspects-techniques/normalisation-base-de-donnees/#:~:text=Par%20exemple%2C%20le%20client%20portant,sous%20le%20code%20postal%2056789.>

- Le tableau suivant présente les données de facturation stockées d'un fournisseur fictif d'équipements de bureau.
 - John Public a commandé 10 moniteurs, 12 tapis de souris et 1 chaise de bureau pour son entreprise.
 - La commande de Jane Doe comprend 2 ordinateurs portables et 2 casques d'écoute.

Détails de la facture									
Fact. N°.	Date	client	N° Client	Adresse	N° inventaire	Produit	N° Produit	No.	Prix
123	29/01/2018	John Public	11	35 Wood Lane, Springfield, ME 04487	1	Monitor	2-0023-D	10	\$200
123	29/01/2018	John Public	11	35 Wood Lane, Springfield, ME 04487	2	Tapis de souris	4-0023-D	12	50c
123	29/01/2018	John Public	11	35 Wood Lane, Springfield, ME 04487	3	Chaise	5-0023-D	1	\$120
124	30/01/2018	Jane Doe	12	72 Windy Road, Springfield, ME 04487	1	Ordinateur	1-0023-D	2	\$1,200
124	30/01/2018	Jane Doe	12	72 Windy Road, Springfield, ME 04487	2	Casque	3-0023-D	2	\$75

CLAUDE BOUBY - JÉRÔME C

53

53

■ 1ère FN

■ Données non atomiques

Solution :

Diviser les attributs client et adresse :
 - prénom et nom de famille,
 - adresse, ville, CP, Etat

Fact. N°.	Date	Client	N° Client	Adresse	N° inventaire	Produit	N° Produit	No.	Prix
123	29/01/2018	John Public	11	35 Wood Lane, Springfield, ME 04487	1	Monitor	2-0023-D	10	\$200

Fact. N°.	Date	Prénom	Nom	N° Client	Adresse Postale	Ville	Etat	Code Postal	N° inventaire	Produit	N° Produit	No.	Prix en €
123	01/29/2018	John	Public	11	35 Wood Lane	Springfield	ME	04487	1	Monitor	2-0023-D	10	200
123	01/29/2018	John	Public	11	35 Wood Lane	Springfield	ME	04487	2	Tapis de souris	4-0023-D	12	0.50
123	01/29/2018	John	Public	11	35 Wood Lane	Springfield	ME	04487	3	Chaise	5-0023-D	1	120
124	01/30/2018	Jane	Doe	12	72 Windy Road	Springfield	ME	04487	1	Ordinateur	1-0023-D	2	1200
124	01/30/2018	Jane	Doe	12	72 Windy Road	Springfield	ME	04487	2	Casque	3-0023-D	2	75

CLAUDE BOUBY - JÉRÔME GRASSET

54

54

■ 3 FN

- Table FACTURE : le nom et le prénom, l'adresse, la ville, l'état et le code postal dépendent non seulement de la clé primaire (le numéro de facture), mais aussi du numéro du client
- Table POSTE FACTURE : les attributs produits et prix dépendent non seulement de la clé primaire, dérivée du numéro de facture et du numéro de poste de facture, mais aussi du numéro de produit.

Solution :

4 tables normalisées :
Facture, Client, Poste de Facture
et Produit.

Facture								
Fact. N°	Date	Prénom	Nom	N° Client	Adresse Postale	Ville	Etat	Code postal
18	John	Public	11	35 Wood Lane	Springfield	ME	04487	
18	Jane	Doe	12	72 Windy Road	Springfield	ME	04487	

Poste de Facture					
Fact. N°	N° inventaire	Produit	N° Produit	No.	Prix en €
123	1	Monitor	2-0023-D	10	200
123	2	Mousepad	4-0023-D	12	0.50
123	3	Chair	5-0023-D	1	120
124	1	Laptop	1-0023-D	2	1200


- BDD AV

janv.-26

57

57

■ Solution finale :



CLAUDE BOUBY - JÉRÔME

Q - R4.03 - BDD AV

26

58

58

DENORMALISATION

- **2 raisons** de dénormaliser une BDD
 - **L'optimisation** pour des gains de performances
 - Adapter une BDD au **datawarehouse**
- **Principe :**
 - La démarche consiste à partir d'un **schéma normalisé** puis à le dénormaliser.
 - Normalisation : minimiser les données redondantes
 - Dénormalisation (optimisation) : ajout de données redondantes à une ou plusieurs tables afin de limiter le nombre de jointures

■ Les techniques d'optimisation

- **Ajouter des données redondantes** pour améliorer les performances des requêtes.
- Ajouter des **données calculées**.
- Simplifier l'accès aux données en stockant toutes les **données au même endroit**.
- Simplifier les requêtes en **réduisant le nombre de jointures** requises, ce qui peut accélérer l'exécution des requêtes.
- **simplifier le schéma** de la base de données et le rendre plus facile à gérer.

■ Cloisonnement vertical

- Divise une table en tables plus petites en fonction des colonnes pour améliorer les performances des requêtes
- Réduit les opérations d'E/S en lisant uniquement les colonnes pertinentes du disque
- Simplifie l'accès aux données en stockant les données dans des tables avec moins de colonnes

■ Cloisonnement horizontal

- Divise une table en tables plus petites en fonction des lignes pour améliorer les performances et l'évolutivité des requêtes
- Simplifie la gestion des données en décomposant les grandes tables en éléments plus petits et plus faciles à gérer
- Augmente les performances des requêtes en réduisant la quantité de données à analyser

- Peut donner lieu à un schéma plus complexe avec plus de tables et de relations
- Peut avoir un impact négatif sur les performances des requêtes

■ Exemple :

- Structurer une table des ventes journalières de plusieurs magasins d'une chaîne
 - Les attributs : MagId, Jour, CA CA (ChiffresAffaires)
- 2 solutions :
 - Représentation Verticale PK = MagId, Jour
 - Représentation Horizontale PK = MagId

Magasin_V
<u>MagId</u>
<u>Jour</u>
ChiffreAffaires

Magasin_H
<u>MagId</u>
ChiffreAffairesJ1
ChiffreAffairesJ2
...
ChiffreAffairesJ7

- Critique : Magasin_H peu évolutive

Dénormalisation

■ Avantages :

- Accès aux données plus rapide
 - moins de tables ou moins de lignes dans les tables
- Des requêtes plus simples.

■ Inconvénients :


- Demande un effort supplémentaire pour les mises à jour et les insertions.
- Prend le risque de données qui peuvent être incohérentes (problème de redondances introduites par la dénormalisation), réduit la garantie de l'intégrité des données.
- Réduit la flexibilité (modification du schéma de BDD plus difficile).

DATA WAREHOUSE (ENTREPÔT DE DONNÉES) DW



- Le **datawarehouse** est un outil de l'informatique décisionnelle, ou **business intelligence BI**.
- C'est un système centralisé de stockage de données provenant de différentes sources (la plupart du temps un ensemble de databases).
- L'objectif : analyser des données, faire des rapports, s'appuyer sur ces informations pour prendre des décisions stratégiques.
- Les données sont **historiques et cumulatives**. Elles sont organisées et structurées de manière à permettre leur traitement et leur analyse.

<https://blog.hubspot.fr/marketing/datawarehouse>
<https://ryax.tech/fr/quest-ce-quun-data-warehouse/>
<https://www.oracle.com/fr/database/data-warehouse-definition/#:~:text=Un%20Data%20Warehouse%20est%20une,pour%20une%20meilleure%20business%20intelligence.>



<https://blog.hubspot.fr/marketing/datawarehouse>

CLAUDE BOUBY - JÉRÔME GRASSET

BUT2 INFO - R4.03 - BDD AV

janv.-26

65

65

■ Quelques définitions :

■ ETL (Extract Transform Load)

- Processus d'extraction et de collection des données qui peut être automatisé ou éventuellement manuel.

■ OLAP (OnLine Analytical Processing) :

- Outils de traitement analytique en ligne des données, qui permettent de les organiser pour les rendre plus adaptées à l'analyse.

■ Outils d'accès : des outils de reporting – d'analyse - de data mining

■ Datamart DM (Magasins de données)

- Sous-ensembles d'un entrepôt de données qui répondent aux besoins spécifiques d'un métier, d'un seul thème.



CLAUDE BOUBY - JÉRÔME GRASSET

BUT2 INFO - R4.03 - BDD AV

janv.-26

66

66

■ Des acteurs majeurs :



- Amazon avec Amazon Redshift,
- Oracle avec Oracle Autonomous Datawarehouse
- IBM avec IBM Db2 Warehouse

■ Avenir du Data Warehouse

- DW dispositif ancien (+ 30 ans)
- Data lake apparu peu avant le Big Data (2010)
 - Capable de stocker des données brutes structurées ou non, des volumétries considérables
 - Des usages différents du data warehouse
 - Différentes solutions (NoSQL, Hadoop, Google Cloud Platform, Microsoft Azure...)

■ Data Lake

- Apparus avec l'émergence du Big Data
- Les data lake sont des espaces de stockage aux **capacités considérables**.
- Un data lake est capable de **stocker sans modélisation** préalable, **des données brutes** (structurées ou non)
- La **qualité prédominante des data lake est donc la flexibilité**.
- Les data lake font appel à des **technologies open source** d'où un coût d'exploitation intéressant, contrairement au data warehouse (avec des logiciels sous licence éditeurs).
- Les données sont utilisées par des data scientists et non dédiées aux utilisateurs métier.

■ Comparaison DataWarehouse / Data Lake

	Data Warehouse	Data Lake
Nature des données	Données structurées	Données brutes, structurées et non structurés
Usages	Banque, finance, industrie hôtelière, services publics, machine learning (IA)	Santé, Éducation, transport, Deep Learning (IA)
Technologie	Ab Initio Software, Amazon Redshift, AnalytiX DS, CodeFutures...	NoSQL, Hadoop, Google Cloud Platform, Microsoft Azure...
Métiers et/ou utilisateurs	Tous les spécialistes internes	Data Scientists, Data Architects
Approche d'exploitation	Usage spécifique connu à l'avance	Usage spécifique non déterminé

■ Les techniques d'adaptation au Data Warehouse

■ Le schéma en étoile

■ Principe

- Technique de modélisation de données utilisé dans le **datawarehouse** (schéma dénormalisé).
- Les données sont organisées dans une table centrale (le centre de l'étoile) qui contient les *mesures* nécessaires aux analyses, entourée de tables (tables de *dimensions*) qui décrivent les attributs des mesures.
- C'est un schéma fondamental parmi les schémas de datamart et il est le plus simple
- Le plus couramment utilisé aujourd'hui.

■ Avantages :

- Simplifie les requêtes et apporte de bonnes performances pour l'interrogation de grands ensembles de données.
- Schéma facile à comprendre. Permet d'alimenter des cubes.


■ Inconvénients :

- Intégrité des données non garantie – peu flexible




■ Exemple :

- La **table de faits** contient
 - les clés de chaque table de dimension telles que Dealer_ID, ID de modèle...
 - d'autres attributs de faits tels que les unités vendues et le chiffre d'affaires.
- Les tables de **dimension**
 - Un niveau
 - Contiennent 1 clé primaire et attributs de description
 - Pas normalisées
 - Non liées entre elles
- Les tables de faits sont généralement plus grandes que les tables de dimensions




■ Le schéma en flocon de neige

- Points clés
 - Utilisé dans le **datawarehouse**
 - C'est une extension d'un schéma en étoile
 - Il ajoute des dimensions supplémentaires.
- Avantages :
 - Plus facile à maintenir que le schéma étoile,
 - Réduit la redondance et consomme moins d'espace de stockage
- Inconvénients :
 - Les requêtes complexes sont difficiles à comprendre et le temps d'exécution des requêtes est plus long.



■ Exemple :

- Les tables de dimension sont normalisées
- divise les données en tables supplémentaires.



■ Le schéma en constellation/ galaxy

- une collection d'étoiles, d'où son nom
- utile pour agréger des tables de faits afin d'améliorer la compréhension du schéma
- donne plusieurs « entrées » dans la base, donc des utilisations plus diverses (plus de faits à analyser)

- Dans l'exemple :
 - 2 tables de faits

